

## **Prediksi Tiga Harga Saham Perusahaan Kapitalisasi Terbesar pada *PSE Composite Index* dengan Algoritme *Recurrent Neural Network-Long Short Term Memory***

Hilmi Farhan Ramadhani (G64160042), Muhammad Arioni Putra Perkasa (G64160064), Rijal Triadi (G64160102), Willyam (G64160065)<sup>1\*</sup>  
Kelompok: 1, Kelas Paralel: 1

### **Abstrak**

Pasar modal adalah suatu pasar yang beroperasi secara terorganisir dimana terdapat aktivitas perdagangan surat-surat berharga seperti saham, ekuitas, surat pengakuan hutang, obligasi, dan surat berharga lainnya yang diterbitkan oleh pemerintah maupun perusahaan swasta dengan memanfaatkan jasa perantara, komisioner, dan *underwriter*. Dua pendekatan yang biasa dilakukan oleh para analisis saham dalam memprediksi harga saham adalah analisa teknikal yang berdasarkan data masa lampau dan faktor eksternal yang berdasarkan kondisi makroekonomi, kondisi non-ekonomi dan kondisi perusahaan. Prediksi ini untuk mendapatkan petunjuk lebih awal mengenai harga saham yang akan datang agar dapat merespon kejadian tersebut dengan tepat. Metode yang digunakan untuk tugas akhir ini adalah prediksi dengan algoritme *Recurrent Neural Network-Long Short Term Memory*. Dalam proses pemodelan digunakan berbagai macam parameter yaitu *lag data*, *batch size*, *input unit*, *dropout rate input unit*, *drop out rate hidden unit*, dan *epoch*. Berdasarkan hasil pemodelan diperoleh nilai *Mean Absolute Percentage Error* untuk saham *AYALA CORPORATION*, *GLOBE TELECOM, INC.*, serta *SM INVESTMENTS CORPORATION* masing-masing sebesar 3,12%, 2,35%, dan 5,59%.

Kata Kunci: *close price*, *Mean Absolute Percentage Error*, prediksi, *Recurrent Neural Network-Long Short Term Memory*, saham.

## **PENDAHULUAN**

### **Latar Belakang**

Pasar modal adalah suatu pasar yang beroperasi secara terorganisir dimana terdapat aktivitas perdagangan surat-surat berharga seperti saham, ekuitas, surat pengakuan hutang, obligasi, dan surat berharga lainnya yang diterbitkan oleh pemerintah maupun perusahaan swasta dengan memanfaatkan jasa perantara, komisioner, dan *underwriter*. Pergerakan harga saham ini cenderung non-linear dan non-stasioner yang dipengaruhi oleh banyak faktor, sehingga sangat sulit untuk meramalkan harga saham. Dua pendekatan yang biasa dilakukan oleh para analisis saham dalam memprediksi harga saham adalah analisa teknikal yang berdasarkan data masa lampau dan faktor eksternal yang berdasarkan kondisi makroekonomi, kondisi non-ekonomi dan kondisi perusahaan. Prediksi ini untuk mendapatkan petunjuk lebih awal mengenai harga saham yang akan datang agar

---

<sup>1</sup>Departemen Ilmu Komputer, Fakultas Matematika dan Ilmu Pengetahuan Alam, Institut Pertanian Bogor, Bogor 16680

\*Mahasiswa Program Studi Ilmu Komputer, FMIPA-IPB; Surel: [hilmi\\_fr98@apps.ipb.ac.id](mailto:hilmi_fr98@apps.ipb.ac.id), [muhammad\\_arioni@apps.ipb.ac.id](mailto:muhammad_arioni@apps.ipb.ac.id), [rijal\\_triadi@apps.ipb.ac.id](mailto:rijal_triadi@apps.ipb.ac.id), [willyam\\_vam2709@apps.ipb.ac.id](mailto:willyam_vam2709@apps.ipb.ac.id)

dapat merespon kejadian tersebut dengan tepat. Fungsi yang diimplementasikan dalam metode ini merupakan representasi dari pengaruh data pergerakan harga saham masa lampau dan pengaruh kondisi saat ini yaitu kondisi makroekonomi (tingkat inflasi, tingkat suku bunga, harga minyak) dan kondisi non-ekonomi (pergerakan indeks saham luar negeri) (Rochman & Djunaidy 2014).

Contoh penelitian peramalan harga saham menggunakan RNN-BPTT, dimana pemodelan proyek yang menjadi data inputan adalah *close price* saham pada Bursa Efek Indonesia (BEI). Kemudian dari data *close price* saham-saham ini akan dilakukan peramalan *time series* dengan algoritme *Recurrent Neural Network* yakni algoritme BPTT (*Back-Propagation Through Time*) dimana arsitektur jaringan yang digunakan adalah *Jordan's RNN*, pada *Recurrent Neural Network* terdapat beberapa *feedback loop* di dalam koneksi grafnya. Konsep utama dari BPTT adalah membentangkan jaringan ke dalam waktu dengan meletakkan salinan yang sama dari *Recurrent Neural Network* dan mengatur kembali koneksi jaringan untuk mendapatkan koneksi antara salinan selanjutnya, untuk menghasilkan peramalan yang akurat, parameter yang ada dalam RNN akan diuji seperti *learning rate*, jumlah neuron dan banyaknya data. (Susanti 2017).

Dalam kehidupan sehari-hari seringkali ditemui sejumlah data yang sifatnya berurutan, misalnya data teks berita, ramalan cuaca, sensor, video lalu lintas, dll. *Recurrent Neural Networks* (RNN) merupakan salah satu bentuk arsitektur *Artificial Neural Networks* (ANN) yang dirancang khusus untuk memproses data yang bersambung/ berurutan (*sequential data*). RNN biasanya digunakan untuk menyelesaikan tugas yang terkait dengan data *time series*, misalnya data ramalan cuaca. Sebagai contoh, cuaca hari ini dapat bergantung pada cuaca hari sebelumnya, jika hari sebelumnya mendung, maka kemungkinan hari ini akan hujan. (Yanuar 2018).

## Tujuan

Tujuan dilakukannya penelitian ini adalah untuk mengimplementasikan model *Recurrent Neural Network-Long Short Term Memory* untuk memprediksi harga saham perusahaan terpilih pada *Philippines Stock Exchange Composite Index*.

## Ruang Lingkup dan Batasan

Data yang diolah yaitu data *Philippine Stock Exchange Data* merupakan salah satu dari dua bursa efek di Filipina, dalam datanya terdapat beberapa fitur yaitu *closing price*, *high price*, *low price*, *opening price*, *date*, *trading volume*, *year*, *month*, *day*, *week number*, *day of week number*, *last price*, *price change from last to close*, *percent change from last to close* dan *symbol stock*. Teknik yang digunakan untuk mengolah data menggunakan RNN-LSTM.

Batasan yang diterapkan pada tugas akhir ini adalah:

1. Model yang dibuat hanya untuk memprediksi harga saham sebuah perusahaan, tanpa melihat pengaruhnya kepada harga saham pada *Philippines Stock Exchange* secara agregat.
2. Data yang akan digunakan untuk pemodelan adalah data historis harga saham pada rentang tahun 2008-2017 selama 10 tahun.
3. Penentuan model terbaik hanya berdasarkan akurasi terbaik, tanpa mempertimbangkan waktu komputasi.

## Manfaat

Manfaat yang diharapkan dari penelitian ini adalah pada masa depan dapat dibuat model RNN-LSTM yang dinamis dan otomatis sesuai tren pergerakan saham, agar investor dapat lebih yakin untuk menaruh uangnya pada saham-saham yang memiliki prospek bagus.

## TINJAUAN PUSTAKA

### 1. Pasar Modal

Pasar modal sebagaimana pasar pada umumnya adalah suatu tempat untuk mempertemukan penjual dan pembeli. Perbedaan dengan pasar lainnya adalah pada objek yang diperjualbelikan (Tavinayati dan Qamariyanti 2009). Pasar modal memiliki peranan yang penting bagi perekonomian suatu negara. Pasar modal sebagai pasar berbagai instrumen keuangan jangka panjang yang bisa diperjualbelikan seperti obligasi, saham, reksadana maupun instrumen derivatif lainnya (Azis, Mintarti, dan Nadir 2015). Saham merupakan salah satu instrumen pasar modal yang paling banyak diminati oleh investor, karena mampu memberikan tingkat pengembalian yang menarik (Nurhasanah dan Rahmalia 2014). Tujuan utama dari pasar modal adalah untuk memfasilitasi perdagangan atas klaim terhadap bisnis perusahaan, sehingga pasar modal dapat memberikan dampak yang signifikan terhadap investasi (Nasution 2015).

### 2. Saham

Saham merupakan surat tanda ikut serta investasi modal dalam suatu perusahaan yang berbentuk Perseroan Terbatas (PT). Salah satu pilihan perusahaan mendapatkan modal untuk menjalankan kegiatan perusahaan dengan menerbitkan saham di Bursa Efek Indonesia (BEI). Menurut Darmadji dan Fakhruddin (2011), saham (*stock* atau *share*) dapat didefinisikan sebagai tanda penyertaan atau kepemilikan seseorang atau badan dalam suatu perusahaan atau perseroan terbatas. Saham berwujud selembar kertas yang menerangkan bahwa pemilik kertas tersebut adalah pemilik perusahaan yang menerbitkan surat berharga tersebut. Terdapat dua bentuk keuntungan yang dapat diperoleh oleh pemegang saham dengan membeli saham yaitu dividen dan *capital gain*. Dividen adalah pembagian keuntungan yang diberikan perusahaan penerbit saham tersebut atas keuntungan yang dihasilkan perusahaan. Dividen yang dibagikan perusahaan dapat berupa dividen tunai (*cash dividend*), yaitu kepada setiap pemegang saham diberikan dividen berupa uang tunai dalam jumlah rupiah tertentu untuk setiap saham, atau dapat pula berupa dividen saham (*stock dividend*), yaitu kepada setiap pemegang saham diberikan dividen dalam bentuk saham sehingga jumlah saham yang dimiliki seorang investor akan bertambah dengan adanya pembagian dividen saham tersebut. *Capital gain* adalah selisih harga beli dengan harga jual. Saham dapat didefinisikan “Sebagai tanda penyertaan modal seseorang atau pihak (badan usaha) dalam suatu perusahaan atau perseroan terbatas” (Martalena dan Malinda 2011).

### 3. *Recurrent Neural Network*

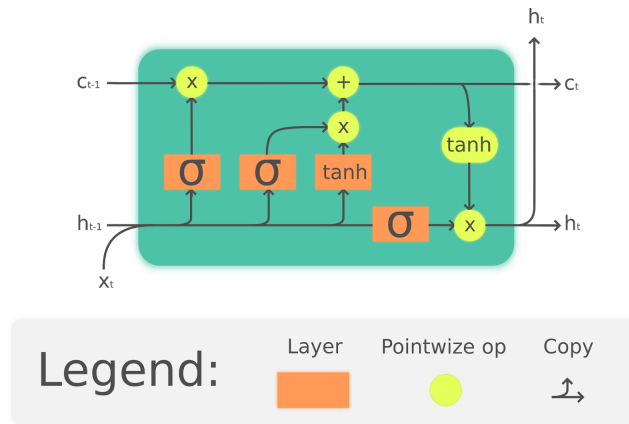
*Recurrent neural network* (RNN) merupakan pengembangan lebih lanjut dari ANN yang memiliki memori sebagai pengingat histori masa lalu. RNN yang juga disebut jaringan umpan balik adalah jenis jaringan pada *neural network* yang terdapat putaran antar neuron sebagai koneksi umpan balik dalam jaringan (Lutfiah 2018). Jaringan RNN adalah jaringan yang mengakomodasi keluaran jaringan untuk menjadi masukan pada jaringan tersebut yang kemudian digunakan untuk menghasilkan output yang baru. Jaringan RNN lebih kompleks dibandingkan dengan jaringan *feedforward neural network* (FNN) (Nanggala *et al.* 2014).

### 4. *Long Short Term Memory* (LSTM)

*Long Short Term Memory* (LSTM) menurut Sen dan Raghunathan (2018) adalah sebuah kelas dari *Recurrent Neural Network* yang sering digunakan untuk banyak pekerjaan *machine learning* yang melibatkan data sekuens, seperti pembangkitan teks, pengenalan suara, dan mesin penerjemah. Seperti RNN, jaringan LSTM (*LSTM network*) juga terdiri dari modul-modul dengan pemrosesan berulang yang performanya sangat superior dan fakta bahwa ia tidak akan mudah menyerah pada masalah gradient yang hilang. Modul LSTM mempunyai pemrosesan yang berbeda dengan modul RNN biasa. Perbedaan lain adalah adanya tambahan sinyal yang diberikan dari satu langkah waktu ke langkah waktu berikutnya. Berikut merupakan cara LSTM menghitung *hidden state*:

$$\begin{aligned}i &= \sigma(x_t U^i + s_{t-1} W^i) \\f &= \sigma(x_t U^f + s_{t-1} W^f) \\o &= \sigma(x_t U^o + s_{t-1} W^o) \\g &= \tanh(x_t U^g + s_{t-1} W^g) \\c_t &= c_{t-1} \circ f + g \circ i \\s_t &= \tanh(c_t) \circ o\end{aligned}$$

*i, f, o* adalah gerbang (*gate*) input, *forget* dan *output*. *forget* dan *output* memiliki rumusan yang sama tetapi berbeda parameter matriks. Mereka disebut *gate* (gerbang) fungsi sigmoid memicu nilai dari vektor-vektor antara 0 dan 1, dan mengalikannya dengan *elementwise vector(o)* lain, kemudian menentukan berapa banyak *vector* yang ingin dibiarkan lewat. *Input gate* mengatur berapa banyak state yang baru saja dikomputasi untuk *current input* yang ingin dibiarkan lewat. *Forget gate* mengatur berapa *state* sebelumnya (*previous*) yang ingin dibiarkan lewat. Terakhir *output gate* mengatur berapa banyak internal state yang ingin diekspos ke jaringan (*network higher layer* dan *next time step*). Semua *gate* memiliki dimensi yang sama dengan *dimension hidden state* sebagai ukuran untuk *hidden state*. Bentuk dari dimensi *gate* dapat dilihat pada gambar 1.



Gambar 1. Bentuk gate pada LSTM

##### 5. *Philippine Stock Exchange Composite Index (PSEi)*

*Philippine Stock Exchange Composite Index (PSEi)* merupakan indeks khusus dari *Philippines Stock Exchange (PSE)*. Indeks ini dibuat dengan harapan pergerakan saham-saham yang termasuk di sana dapat merepresentasikan secara umum pergerakan saham indeks PSE tanpa harus melihat seluruh saham yang telah ada. Sebanyak 30 saham terpilih akan masuk ke indeks khusus tersebut, dengan kriteria menurut *The PSE Academy* (2011) adalah sebagai berikut:

1. Minimum *free-float level* (kepemilikan saham yang dikuasai publik) sebesar 12%.
2. Harus berada dalam urutan 25% teratas pada minimal sembilan dari dua belas bulan dari segi nilai median harga perusahaan secara harian.
3. Berada dalam urutan 30 tertinggi dari segi kapitalisasi pasar penuh.

## METODE

### Data

Dataset yang digunakan untuk tugas akhir adalah *Philippines Stock Exchange Data* yang diperoleh dari situs Kaggle yang merupakan *platform* data yang bersifat terbuka. Data ini berisikan 794.509 baris dan 15 variabel berupa harga pembukaan, harga penutupan, harga tertinggi, harga terendah, *trading volume*, *day*, *month*, *year*, *day of week*, *week number*, tanggal, *last price*, perubahan harga, perubahan harga dalam persen, dan *symbol* perusahaan pada bursa. Data diunduh pada tanggal 11 Maret 2019. Data tersebut memiliki format CSV (*Comma Separated Value*). Penjelasan mengenai variabel dapat dilihat pada tabel 1.

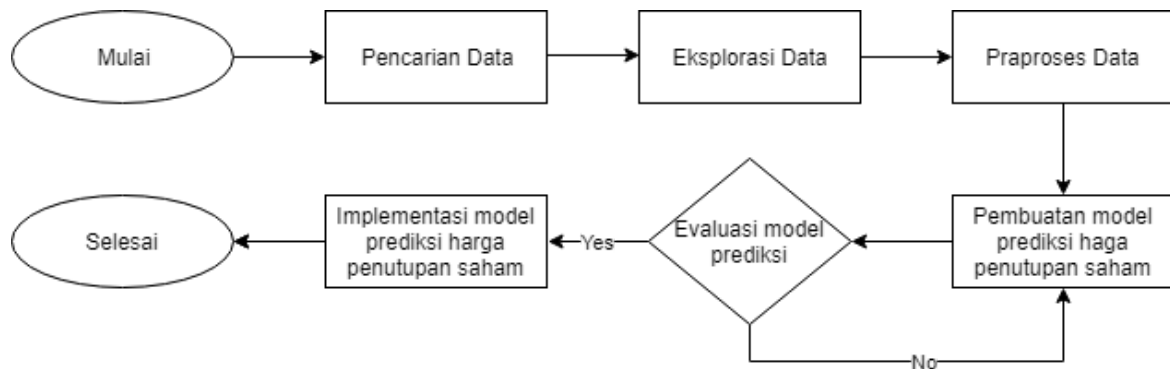
Tabel 1. Variabel pada dataset beserta penjelasannya.

No	Variabel	Penjelasan
1	c	<i>Close price</i> . Harga penutupan ( <i>closing price</i> ) adalah harga yang muncul saat bursa tutup. Harga penutupan saham sangat penting karena menjadi acuan untuk harga pembukaan di keesokan harinya. Harga penutupan biasanya digunakan untuk memprediksi harga saham pada periode berikutnya. Prediksi harga saham di dunia

		investasi menjadi hal yang penting untuk kegiatan jual-beli saham. Prediksi harga saham dapat membantu pelaku pasar untuk memberikan saran mengenai harga saham yang hendak dijual atau dibeli oleh pelaku pasar. Harapannya pelaku pasar dapat keuntungan yang lebih maksimal.
2	h	<i>High price.</i> Harga tertinggi menunjukkan harga tertinggi yang pernah terjadi dalam suatu periode perdagangan.
3	l	<i>Low price.</i> Harga terendah menunjukkan harga terendah yang pernah terjadi dalam suatu periode perdagangan.
4	o	<i>Open price.</i> Harga <i>open</i> atau harga pembukaan adalah harga pertama kali transaksi dilakukan pada hari itu. Harga tersebut mencerminkan semua informasi pasar yang ada, yang terjadi atau muncul diantara harga penutupan sehari sebelumnya dan ketika saat-saat terakhir pemodal boleh memasukkan order ke mesin bursa.
5	t	<i>Date.</i> Tanggal lengkap dalam format “yyyy-mm-dd”
6	v	<i>Trading volume.</i> Jumlah lembar saham yang diperdagangkan secara harian.
7	y	<i>Year.</i> Memberikan informasi tahun
8	m	<i>Month.</i> Memberikan informasi bulan
9	d	<i>Day.</i> Memberikan informasi tanggal dalam bulan
10	w	<i>Week number.</i> Memberi informasi urutan minggu dalam satu tahun.
11	wd	<i>Day of week number.</i> Memberikan informasi urutan hari dalam seminggu.
12	last	<i>Last price.</i> Harga penutupan di hari kerja sebelumnya yang akan dibandingkan dengan harga penutupan hari kerja saat ini.
13	change	<i>Price change from last to close.</i> Perubahan harga dari harga terakhir ke harga penutupan.
14	pchange	<i>Percent price change from last to close.</i> Perubahan harga dari harga terakhir ke harga penutupan dalam persen.
15	symbol	<i>Stock symbol.</i> Simbol saham yang dimiliki oleh suatu perusahaan yang diwakili oleh dua sampai empat karakter.

## Tahapan Kegiatan

Tahapan awal dari kegiatan penambangan data yaitu mengunduh dataset yang diperoleh dari situs Kaggle. Tahapan secara detail dapat dilihat pada gambar 2.



Gambar 2. Tahapan penelitian.

## Lingkungan Pengembangan

Perangkat keras yang digunakan dalam penelitian ini adalah komputer personal dengan spesifikasi sebagai berikut:

1. Prosesor: Intel Core i5-5200U 2.20GHz
2. Memori: 8 GB
3. VGA: NVIDIA GeForce GT 940M

Perangkat lunak yang digunakan dalam penelitian ini adalah sebagai berikut:

1. Sistem operasi Microsoft Windows 10 (64-bit)
2. Bahasa pemrograman R versi 3.5.1 untuk pemrosesan bahasa R
3. RStudio 1.1.423 untuk mengolah data tabular
4. *Library package* “keras”, “kerasR”, dan “tensorflow” untuk pembuatan model *deep learning* RNN-LSTM.
5. *Library package* “dplyr” untuk praproses data
6. *Library package* “plotly” untuk visualisasi hasil prediksi.

## Praproses dan Eksplorasi Data

Proses meminimalkan *error* dapat dilakukan dengan teknik normalisasi *min max normalization*, yang mengubah data aktual menjadi data dengan *range interval* [0-1] pada dataset. Rumus *min max normalization* menurut Patro dan Sahu (2015) adalah:

$$X' = \frac{(x - \min(x))}{(\max(x) - \min(x))}$$

Keterangan :

$x$  = Data yang akan dinormalisasikan

$X'$  = Data yang akan dinormalisasikan

$\min(x)$  = Nilai minimum dari seluruh data

$\max(x)$  = Nilai maksimum dari seluruh data

Pada tahap eksplorasi data, data yang diperoleh mempunyai jumlah baris yang sangat banyak. Hal ini disebabkan karena pada dataset ini merupakan kompilasi dari

seluruh saham perusahaan yang pernah atau sedang melantai di Bursa Efek Filipina sejak tahun 1983 hingga 19 Februari 2018.

Berdasarkan pertimbangan relevansi data dan nilai kapitalisasi pasar dari saham tersebut, akan diambil tiga saham yang memiliki nilai kapitalisasi pasar terbesar dari indeks *Philippines Stock Exchanges Composite Index* (PSEi), untuk diambil data historisnya sejak tanggal 1 Januari 2008 hingga 31 Desember 2017 (10 tahun). Ketiga saham tersebut adalah saham dari *AYALA CORPORATION* (AC), *GLOBE TELECOM, INC.* (GLO), dan *SM INVESTMENTS CORPORATION* (SM). Sehingga tahapan praproses yang dilakukan agar data siap untuk masuk tahap pemodelan membutuhkan empat langkah berikut:

1. Perubahan nama variabel dan penyesuaian format variabel (*date* untuk variabel *date*, dan karakter untuk variabel *symbol*)
2. Pengambilan variabel yang dibutuhkan. Diambil empat variabel yang cukup untuk digunakan pada proses pemodelan dan visualisasi, yaitu variabel *date*, *close price*, *trading volume*, dan *symbol*.
3. Menyaring data sehingga yang diambil hanya saham dari perusahaan *AYALA CORPORATION* (AC), *GLOBE TELECOM, INC.* (GLO), dan *SM INVESTMENTS CORPORATION* (SM).
4. Melakukan normalisasi nilai (dalam rentang 0-1) pada variabel *close price* untuk pemodelan RNN-LSTM.

Keempat tahapan praproses tersebut mengaplikasikan teknik praproses *Data Cleaning* (langkah 1), *Data Reduction* (langkah 2 dan 3), dan *Data Transformation* (langkah 4).

### **Tahapan Pemodelan**

Secara umum tahapan pemodelan sistem LSTM terdiri dari *Preprocessing Data*, inialisasi parameter, training LSTM Network menggunakan optimizer *Adaptive Moment Estimation* (ADAM), dan melakukan uji terhadap *data testing*. Dataset diolah terlebih dahulu menggunakan teknik normalisasi *min max normalization*. Dilakukan inialisasi terhadap setiap parameter, setelah itu dilakukan *training* pada jaringan yang dibuat sesuai dengan parameter yang sudah ditentukan. Selanjutnya dilakukan uji pada model yang telah didapatkan dari proses *training* terhadap *data testing*, Proses diulang-ulang sampai mendapatkan model dengan *Mean Absolute Percentage Error* (MAPE) yang dapat diterima.

### **Inisialisasi Parameter**

Inisialisasi parameter-parameter dasar dalam pemodelan RNN-LSTM, yaitu:

- 1) Jumlah *Hidden Layer*
- 2) Jumlah *Neuron* pada setiap *Hidden Layer*
- 3) *Epoch* Maksimum
- 4) *Batch Size*
- 5) Banyak *Lag Data*
- 6) *Dropout Rate* pada setiap *Hidden Layer*



### **Training LSTM Network**

Proses *training* pada jaringan *LSTM Network* menggunakan *optimizer Adaptive Moment Estimation* (ADAM). Proses pelatihan model dan optimasi oleh ADAM akan dijelaskan melalui lima tahap berikut:

1. Hitung semua fungsi *gates unit* pada setiap neuron dengan urutan yang pertama adalah *forget gates* yaitu *gates* yang mengolah informasi dari *input data* dan memilih data mana yang akan disimpan atau dibuang pada *memory cells*. Fungsi aktivasi yang digunakan pada *forget gates* adalah fungsi aktivasi sigmoid dengan nilai *output* antara nol dan satu. Jika *output* sama dengan satu maka data akan disimpan dan jika *output* nol maka semua data akan dibuang. Rumus dapat ditulis sebagai seperti berikut:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

Keterangan Variabel :

$f_t$	= Forget Gates Activation Vector
$\sigma$	= Sigmoid Function
$W_f$	= Weight
$h_{t-1}$	= Previous Hidden State Vector
$x_t$	= Input Vector
$b_f$	= Bias Vector Parameters

2. Selanjutnya fungsi *input gates* dimana terdapat dua *gates* yang akan dilaksanakan, pertama akan diputuskan nilai mana yang akan diperbarui menggunakan fungsi aktivasi sigmoid. Selanjutnya fungsi aktivasi tanh akan membuat vektor nilai baru dan disimpan dalam *memory cell* dengan persamaan kedua *gates*:

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$
$$\check{c}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c)$$

Keterangan Variabel :

$i_t$	= Input Gate Activation Vector
$\sigma$	= Sigmoid Function
$W_i, W_c$	= Weight
$\check{c}_t$	= Memory Cell
$h_{t-1}$	= Previous Hidden State Vector
$x_t$	= Input Vector
$b_i, b_c$	= Bias Vector Parameters
$\tanh$	= Hyperbolic Tangent Function

3. *Cell gates* akan mengganti nilai pada *memory cell* sebelumnya dengan nilai *memory cell* yang baru. Nilai ini didapatkan dari menggabungkan nilai yang terdapat pada *forget gate* dan *input gate*. Rumusnya dapat dinyatakan sebagai berikut:

$$c_t = f_t \cdot c_{t-1} + i_t \cdot \check{c}_t$$

Keterangan Variabel :

$c_t$	= Previous Cell State Vector
$i_t$	= Input Gate's Activation Vector
$f_t$	= Forget Gates Activation Vector
$c_{t-1}$	= Previous Cell State Vector

$i_t$  = *Input Gate's Activation Vector*  
 $\check{c}_t$  = *Memory Cell*

4. Pada *output gates* terdapat dua gates yang akan dilaksanakan, pertama akan diputuskan nilai pada bagian *memory cell* terpilih yang akan dikeluarkan dengan menggunakan fungsi aktivasi sigmoid. Selanjutnya akan ditempatkan nilai pada *memory cell* dengan menggunakan fungsi aktivasi tanh (*hyperbolic tangent*). Terakhir kedua *gates* tersebut dikalikan dengan menghasilkan nilai yang akan dikeluarkan. Rumusnya dapat dinyatakan sebagai berikut:

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$$

$$h_t = \sigma_t \tanh(c_t)$$

Keterangan Variabel :

$o_t$  = *Output Gate*  
 $W_o$  = *Weight*  
 $h_{t-1}$  = *Previous Hidden State Vector*  
 $x_t$  = *Input Vector*  
 $b_o$  = *Bias Vector Parameters*

5. Berikutnya optimisasi dengan menggunakan *Adaptive Moment Estimation Optimization* (ADAM) yaitu perluasan untuk *stochastic gradient descent* yang baru-baru ini telah digunakan sebagai pembelajaran yang mendalam dalam *computer vision* dan *natural language processing*. Pertama kali diperkenalkan oleh Diederik Kingma dari OpenAI dan Jimmy Ba dari Universitas Toronto (2015). ADAM merupakan algoritma optimasi yang mengembangkan dengan memanfaatkan kelebihan dari algoritme *Adaptive Gradient* (AdaGrad) dan *Root Mean Square Propagation* (RMSProp). Alih-alih mengadaptasi tingkat pembelajaran parameter berdasarkan rata-rata pertama (*mean*) seperti dalam RMSProp, ADAM juga menggunakan rata-rata kedua dari gradien (*variance uncentered*). Algoritme ADAM menghitung rata-rata pergerakan eksponensial dari gradien dan gradien kuadratnya, serta parameter beta 1 dan beta 2 yang dapat mengontrol tingkat peluruhan rata-rata pergerakan. Langkah algoritme optimasi ADAM dapat dijelaskan dengan *pseudocode* dan parameter sebagai berikut:

$\alpha$  : *Learning Rate (Best Learning Rate : 0.001)*  
 $\beta_1, \beta_2 \in [0, 1)$  : *Exponential decay rates for the moment estimates*  
 ( $\beta_1 = 0.9, \beta_2 = 0.999$  , konstan)  
 $f(\theta)$  : fungsi stokastik dengan parameter  $\theta$   
 $\theta_0$  : Inisial parameter vektor  
 $m_0 \leftarrow 0$  : Inisialisasi momen vektor pertama  
 $v_0 \leftarrow 0$  : Inisialisasi momen vektor kedua  
 $t \leftarrow 0$  : Inisialisasi *timestep*

#### ***Pseudocode* algoritme optimasi ADAM**

Tahapan sederhana (*pseudocode*) dari algoritme optimasi ADAM menurut Aldi, Jondri, dan Aditsania (2018) adalah sebagai berikut:

```

while  $\theta_t$  not converged do
   $t \leftarrow t + 1$ 
   $g_t \leftarrow \Delta_{\theta} f_t(\theta_{t-1})$  (Mendapatkan gradien dari fungsi stokastik pada timestep t)
   $m_t \leftarrow \beta_1 \cdot m_{t-1} + (1 - \beta_1) \cdot g_t$  (Update bias estimasi momen pertama)
   $v_t \leftarrow \beta_1 \cdot v_{t-1} + (1 - \beta_1) \cdot g_t^2$  (Update bias estimasi momen kedua)
   $\hat{m}_t \leftarrow m_t / (1 - \beta_1^t)$  (menghitung koreksi bias dari estimasi momen pertama)
   $\hat{v}_t \leftarrow v_t / (1 - \beta_2^t)$  (menghitung koreksi bias dari estimasi momen kedua)
   $\theta_t \leftarrow \theta_{t-1} - a \cdot \hat{m}_t / (\sqrt{\hat{v}_t} + \epsilon)$  (Update parameter)
End while
Return  $\theta_t$  (Hasil parameter yang didapatkan)

```

6. Menghitung *Mean Absolute Percentage Error (MAPE)* dengan rumus:

$$\frac{100\%}{n} \sum_{t=1}^n \left| \frac{A_t - F_t}{A_t} \right|$$

Keterangan:

$A_t$  = data aktual  
 $F_t$  = data prediksi  
 $n$  = banyaknya data

### Uji Model

Tahapan uji model adalah menguji beberapa parameter terhadap nilai MAPE yang didapatkan. Berikut adalah nilai parameter yang akan diuji pada saham AC, GLO, SM:

- 1) *Lag Data*: 2, 5, 10
- 2) *Batch Size*: 3, 10, 15; khusus saham SM: 1, 7
- 3) *Unit Input*: 15, 20, 25
- 4) *Dropout Rate Input*: 0.00001, 0.0005, 0.01
- 5) *Dropout Rate Hidden*: 0.001, 0.01, 0.05
- 6) *Max Epoch*: 50, 170, 500

### Uji Model dan *Parameter Tuning* pada Saham AC

Berikut akan dilakukan pengujian berbagai model dan melakukan *tuning* secara bertahap pada parameter untuk melihat manakah parameter keseluruhan yang dapat meminimumkan nilai MAPE. Proses *tuning* dan hasil dari setiap jenis parameter untuk saham AC dapat dilihat dalam Tabel 2 hingga Tabel 7. Hasil terbaik akan diberi warna khusus sebagai penanda bahwa model tersebut yang akan digunakan dan ditampilkan hasilnya pada bagian hasil dan pembahasan.

Tabel 2. Perbandingan parameter *lag data* untuk pemodelan prediksi saham AC.

<i>lag data</i>	<i>batch size</i>	<i>unit input</i>	<i>dropout rate input</i>	<i>dropout rate hidden</i>	<i>epoch</i>	<i>MAPE test</i>
2	15	15	0.01	0.05	100	5.49%
5	15	15	0.01	0.05	100	43.24%

10	15	15	0.01	0.05	100	3.59%
----	----	----	------	------	-----	-------

Tabel 3. Perbandingan parameter *batch size* untuk pemodelan prediksi saham AC.

<i>lag data</i>	<i>batch size</i>	<i>unit input</i>	<i>dropout rate input</i>	<i>dropout rate hidden</i>	<i>epoch</i>	<i>MAPE test</i>
10	3	15	0.01	0.05	100	6.74%
10	10	15	0.01	0.05	100	41.50%
10	15	15	0.01	0.05	100	3.59%

Tabel 4. Perbandingan parameter *unit input* untuk pemodelan prediksi saham AC.

<i>lag data</i>	<i>batch size</i>	<i>unit input</i>	<i>dropout rate input</i>	<i>dropout rate hidden</i>	<i>epoch</i>	<i>MAPE test</i>
10	15	15	0.01	0.05	100	3.56%
10	15	20	0.01	0.05	100	3.89%
10	15	25	0.01	0.05	100	3.77%

Tabel 5. Perbandingan parameter *dropout rate input* untuk pemodelan prediksi saham AC.

<i>lag data</i>	<i>batch size</i>	<i>unit input</i>	<i>dropout rate input</i>	<i>dropout rate hidden</i>	<i>epoch</i>	<i>MAPE test</i>
10	15	15	0.00001	0.05	100	3.53%
10	15	15	0.0005	0.05	100	3.20%
10	15	15	0.01	0.05	100	3.12%

Tabel 6. Perbandingan parameter *dropout rate hidden* untuk pemodelan prediksi saham AC.

<i>lag data</i>	<i>batch size</i>	<i>unit input</i>	<i>dropout rate input</i>	<i>dropout rate hidden</i>	<i>epoch</i>	<i>MAPE test</i>
10	15	15	0.01	0.001	100	3.80%
10	15	15	0.01	0.01	100	4.55%
10	15	15	0.01	0.05	100	4.01%

Tabel 7. Perbandingan parameter *max epoch* untuk pemodelan prediksi saham AC.

<i>lag data</i>	<i>batch size</i>	<i>unit input</i>	<i>dropout rate input</i>	<i>dropout rate hidden</i>	<i>epoch</i>	<i>MAPE test</i>
10	15	15	0.01	0.001	50	4.41%
10	15	15	0.01	0.001	170	4,33%
10	15	15	0.01	0.001	500	3,34%

### Uji Model dan *Parameter Tuning* pada Saham GLO

Selanjutnya akan dilakukan pengujian berbagai model dan melakukan *tuning* secara bertahap pada parameter untuk melihat manakah parameter keseluruhan yang dapat meminimumkan nilai MAPE pada saham GLO. Proses *tuning* dan hasil dari setiap jenis parameter untuk saham ini dapat dilihat dalam tabel 8 hingga tabel 13. Hasil terbaik akan diberi warna khusus sebagai penanda bahwa model tersebut yang akan digunakan dan ditampilkan hasilnya pada bagian hasil dan pembahasan.

Tabel 8. Perbandingan parameter *lag data* untuk pemodelan prediksi saham GLO.

<i>lag data</i>	<i>batch size</i>	<i>unit input</i>	<i>dropout rate input</i>	<i>dropout rate hidden</i>	<i>epoch</i>	<i>MAPE test</i>
2	15	15	0.01	0.05	50	3,788%
5	15	15	0.01	0.05	50	31,57%
10	15	15	0.01	0.05	50	5,32%

Tabel 9. Perbandingan parameter *batch size* untuk pemodelan prediksi saham GLO.

<i>lag data</i>	<i>batch size</i>	<i>unit input</i>	<i>dropout rate input</i>	<i>dropout rate hidden</i>	<i>epoch</i>	<i>MAPE test</i>
2	3	15	0.01	0.05	50	5,45%
2	10	15	0.01	0.05	50	2,88%
2	15	15	0.01	0.05	50	3,788%

Tabel 10. Perbandingan parameter *unit input* untuk pemodelan prediksi saham GLO.

<i>lag data</i>	<i>batch size</i>	<i>unit input</i>	<i>dropout rate input</i>	<i>dropout rate hidden</i>	<i>epoch</i>	<i>MAPE test</i>
2	10	15	0.01	0.05	50	2,88%
2	10	20	0.01	0.05	50	4,95%
2	10	25	0.01	0.05	50	4,3%

Tabel 11. Perbandingan parameter *dropout rate input* untuk pemodelan prediksi saham GLO.

<i>lag data</i>	<i>batch size</i>	<i>unit input</i>	<i>dropout rate input</i>	<i>dropout rate hidden</i>	<i>epoch</i>	<i>MAPE test</i>
2	10	15	0.00001	0.05	50	3,5%
2	10	15	0.0005	0.05	50	3,36%
2	10	15	0.01	0.05	50	2,88%

Tabel 12. Perbandingan parameter *dropout rate hidden* untuk pemodelan prediksi saham GLO.

<i>lag data</i>	<i>batch size</i>	<i>unit input</i>	<i>dropout rate input</i>	<i>dropout rate hidden</i>	<i>epoch</i>	<i>MAPE test</i>
2	10	15	0.01	0.001	50	3,25%
2	10	15	0.01	0.01	50	2,69%
2	10	15	0.01	0.05	50	2,88%

Tabel 13. Perbandingan parameter *max epoch* untuk pemodelan prediksi saham GLO.

<i>lag data</i>	<i>batch size</i>	<i>unit input</i>	<i>dropout rate input</i>	<i>dropout rate hidden</i>	<i>epoch</i>	<i>MAPE test</i>
2	10	15	0.01	0.01	50	2,69%
2	10	15	0.01	0.01	170	2,46%
2	10	15	0.01	0.01	500	2,35%

### Uji Model dan *Parameter Tuning* pada Saham SM

Terakhir akan dilakukan pengujian berbagai model dan melakukan *tuning* secara bertahap pada parameter untuk melihat manakah parameter keseluruhan yang dapat meminimumkan nilai MAPE. Proses *tuning* dan hasil dari setiap jenis parameter untuk saham SM dapat dilihat dalam tabel 14 hingga tabel 19. Hasil terbaik akan diberi warna khusus sebagai penanda bahwa model tersebut yang akan digunakan dan ditampilkan hasilnya pada bagian hasil dan pembahasan.

Tabel 14. Perbandingan parameter *lag data* untuk pemodelan prediksi saham SM.

<i>lag data</i>	<i>batch size</i>	<i>unit input</i>	<i>dropout rate input</i>	<i>dropout rate hidden</i>	<i>epoch</i>	<i>MAPE test</i>
2	7	15	0.01	0.05	50	7.06%

5	7	15	0.01	0.05	50	20.89%
10	7	15	0.01	0.05	50	7.63%

Tabel 15. Perbandingan parameter *batch size* untuk pemodelan prediksi saham SM.

<i>lag data</i>	<i>batch size</i>	<i>unit input</i>	<i>dropout rate input</i>	<i>dropout rate hidden</i>	<i>epoch</i>	<i>MAPE test</i>
2	1	15	0.01	0.05	50	9.68%
2	7	15	0.01	0.05	50	7.02%

Tabel 16. Perbandingan parameter *unit input* untuk pemodelan prediksi saham SM.

<i>lag data</i>	<i>batch size</i>	<i>unit input</i>	<i>dropout rate input</i>	<i>dropout rate hidden</i>	<i>epoch</i>	<i>MAPE test</i>
2	7	15	0.01	0.05	50	7.02%
2	7	20	0.01	0.05	50	8.15%
2	7	25	0.01	0.05	50	8.55%

Tabel 17. Perbandingan parameter *dropout rate input* untuk pemodelan prediksi saham SM.

<i>lag data</i>	<i>batch size</i>	<i>unit input</i>	<i>dropout rate input</i>	<i>dropout rate hidden</i>	<i>epoch</i>	<i>MAPE test</i>
2	7	15	0.00001	0.05	50	7.34%
2	7	15	0.0005	0.05	50	6.70%
2	7	15	0.01	0.05	50	7.02%

Tabel 18. Perbandingan parameter *dropout rate hidden* untuk pemodelan prediksi saham SM.

<i>lag data</i>	<i>batch size</i>	<i>unit input</i>	<i>dropout rate input</i>	<i>dropout rate hidden</i>	<i>epoch</i>	<i>MAPE test</i>
2	7	15	0.0005	0.001	50	6.18%
2	7	15	0.0005	0.01	50	7.07%
2	7	15	0.0005	0.05	50	6.70%

Tabel 19. Perbandingan parameter *max epoch* untuk pemodelan prediksi saham SM.

<i>lag data</i>	<i>batch size</i>	<i>unit input</i>	<i>dropout rate input</i>	<i>dropout rate hidden</i>	<i>epoch</i>	<i>MAPE test</i>
2	7	15	0.0005	0.001	50	6.18%
2	7	15	0.0005	0.001	170	6.18%
2	7	15	0.0005	0.001	500	5.59%

## HASIL DAN PEMBAHASAN

### Tahap Eksplorasi dan Pra-proses Data

Pada tahap eksplorasi, data yang diperoleh tidak mempunyai nilai *missing value* dan mempunyai 794.509 *instance* dan 15 variabel. Pada 15 variabel tersebut memiliki nama-nama yang singkat, namun pada sumber data yang diperoleh terdapat penjelasan apa maksud dari nama-nama variabel tersebut. Agar lebih mudah untuk memahami dataset, pada saat proses selanjutnya akan diubah nama-nama variabel yang disingkat tersebut sesuai penjelasan yang ada pada tabel 1.


Setelah itu pada variabel *date* memiliki tipe data faktor, karena tidak sesuai maka variabel *date* diubah tipe datanya menjadi *date*, lalu pada variabel *symbol* sebelumnya tipe datanya adalah faktor agar mudah untuk penyaringan data maka tipe data variabel tersebut diubah menjadi *character*. Setelah itu masuk kepada proses reduksi data, karena dari dataset yang diperoleh hanya beberapa yang digunakan untuk proses pemodelan. Data yang diambil yaitu hanya variabel *date*, *close price*, dan *trading volume* karena yang akan diprediksi adalah *close price* dan *trading volume* akan mempengaruhi nilai suatu saham setiap hari. Lalu *symbol* yang hanya diambil hanya *AYALA CORPORATION (AC)*, *GLOBE TELECOM, INC. (GLO)*, dan *SM INVESTMENTS CORPORATION (SM)* karena ketiga saham tersebut memiliki nilai kapitalisasi pasar terbesar dari indeks *Philippines Stock Exchanges Composite Index (PSEi)*. Lalu data saham yang diambil pada tahun 2008 sampai 2017.

Setelah selesai proses *filtering* berdasarkan periode tahun 2008-2017, dataset *AYALA CORPORATION (AC)*, *GLOBE TELECOM, INC. (GLO)*, dan *SM INVESTMENTS CORPORATION (SM)* kemudian dipecah menjadi dataset masing-masing untuk pembuatan model RNN-LSTM. Setelah tahap praproses, dimensi dataset yang diperoleh menjadi 7.289 *instance* dan 3 variabel.

### Model Prediksi pada saham AC


Berdasarkan parameter yang telah disusun dan dijelaskan pada tahapan penelitian bagian pemodelan, berikut merupakan hasil dari pemodelan prediksi harga saham perusahaan *AYALA CORPORATION (AC)* pada gambar 3.





Gambar 3. Plot harga saham dan prediksi dari model LSTM *AYALA CORPORATION* (AC) pada tahun 2008-2017.

Diperoleh nilai *Mean Absolute Percentage Error* dari hasil prediksi saham perusahaan AC sebesar 0.0312 atau 3.12%. Berikut merupakan plot perbandingan prediksi harga *close price* saham AC dengan data yang sebenarnya yang telah diperbesar yang diberikan pada gambar 4.




Gambar 4. Pembesaran plot perbandingan prediksi harga saham AC dengan data aslinya

Terlihat dari gambar bahwa dari hasil model prediksi untuk *close price* saham AC cenderung kurang menangkap secara akurat peningkatan data yang cukup ekstrim pada bagian akhir data, meskipun secara pola sudah cukup mengikuti.


## Model Prediksi pada saham GLO

Saham kedua yang diprediksi adalah saham *GLOBE TELECOM, INC.* (GLO). Plot penuh data *close price* termasuk prediksinya terjadi pada gambar 5.



Gambar 5. Plot perbandingan prediksi *close price* GLO dengan data aslinya.

Secara visual, model prediksi untuk saham GLO jauh lebih akurat dibandingkan saham AC. Terbukti dengan nilai MAPE hasil model prediksi yang diperoleh lebih kecil daripada nilai serupa pada model prediksi saham AC, hanya sebesar 0,0235 atau 2,35%. Plot lebih jelas pada rentang data *testing* dapat dilihat pada gambar 6.




Gambar 6. Plot perbandingan *close price* saham GLO dengan data aslinya yang diperbesar.

Plot yang telah diperbesar tersebut memperlihatkan model LSTM sudah sangat baik memprediksi pergerakan saham GLO tanpa kendala yang berarti. Tidak ditemukan kesalahan yang cukup besar pada model prediksi secara kasat mata, sehingga nilai MAPE yang diperoleh sangat kecil.


### Model Prediksi pada saham SM

Hasil prediksi pada saham SM kurang baik jika dibandingkan dengan prediksi pada saham AC dan GLO. Berikut merupakan hasil prediksi beserta data historis saham SM dalam gambar 7.



Gambar 7. Plot perbandingan prediksi *close price* saham SM dengan data aslinya.

Terlihat cukup jelas bahwa hasil prediksi yang dibuat oleh model belum dapat menangkap pola pergerakan saham SM dengan baik. Secara nilai MAPE, nilai optimum dari uji pemodelan diperoleh sebesar 0.0559 atau 5.59%. Tampilan lebih jelas mengenai prediksi dan data aslinya diperlihatkan pada gambar 8.



Gambar 8. Plot perbandingan hasil model prediksi *close price* SM dengan data aslinya yang diperbesar.

Pola prediksi cenderung salah memprediksi pada periode awal September 2016 dan pada rentang bulan Juli 2017 hingga akhir prediksi yaitu bulan Desember 2017.

## KESIMPULAN DAN SARAN

Kesimpulan dari kegiatan ini adalah telah berhasil dibuat pemodelan RNN-LSTM untuk memprediksi *close price* dari tiga saham pada *Philippines Stock Exchange Composite Index* (PSEi), yaitu *AYALA CORPORATION* (AC), *GLOBE TELECOM, INC.* (GLO), dan *SM INVESTMENTS CORPORATION* (SM). Adapun nilai *Mean Absolute Percentage Error* (MAPE) pada saham AC, GLO, dan SM masing-masing sebesar 3,12%, 2,35%, dan 5,59%.

Saran untuk penelitian selanjutnya adalah menggunakan metode *grid search* untuk *tuning parameter*. Selain itu juga, dapat pula membandingkan pemodelan RNN-LSTM dengan fungsi *optimizer* yang berbeda-beda. Kemudian yang terakhir dapat diuji keakuratan pemodelan RNN-LSTM dengan metode *forecasting* yang lain seperti *Auto Regressive Integrated Moving Average* (ARIMA).

## DAFTAR PUSTAKA

- Aldi MWP, Jondri, Aditsania A. 2018. Implementasi Long Short Term Memory Neural Network untuk Prediksi Harga Bitcoin. *Jurnal e-Proceeding of Engineering*, 5(2), 3548.
- Azis, Mintarti S, Nadir M. 2015. *Manajemen Investasi Fundamental, Teknikal, Perilaku Investor dan Return Saham*. Yogyakarta (ID) : DEEPUBLISH (Grup Penerbitan CV BUDI UTAMA).
- Darmadji, Fakhrudin. 2011. *Pasar Modal di Indonesia, Edisi Ketiga*. Jakarta: Salemba Empat.
- Lutfiah H. 2018. *Prediksi temporal untuk kemunculan titik panas di Kabupaten Rokan Hilir Riau menggunakan Long short term memory RNN* [skripsi]. Bogor(ID): Institut Pertanian Bogor.
- Martalena, Malinda. 2011. *Pengantar Pasar Modal*. Edisi Pertama. Yogyakarta : Andi.
- Nanggala S, Saepudin D, Nhita F. 2016. Analisis dan Implementasi Elman recurrent neural network untuk prediksi harga komoditas pertanian. *e-Proceeding of Engineering*. 3(1):1253-1262.
- Nasution YSJ. 2015. Peranan Pasar Modal dalam Perekonomian Negara. *Jurnal Human Falah*. 2(1): 95-112.
- Nurhasanah, Rahmalia. 2014. Pengaruh ROA, ROE, dan EPS terhadap Harga Saham (Survey pada Perusahaan LQ45 yang Terdaftar di BEI Periode 2007-2011). *Jurnal Akuntansi, Fakultas Ekonomi Universitas Widyatama*. Bandung.
- Patro S, Sahu KK. 2015. Normalization: A Preprocessing Stage. *International Advanced Research Journal in Science, Engineering and Technology*, 2(3): 20-22.
- Rochman EMS, Djunaidy A. 2014. Prediksi Harga Saham yang Mempertimbangkan Faktor Eksternal Menggunakan Jaringan Saraf Tiruan. *Jurnal Ilmiah NERO*. Institut Teknologi Sepuluh Nopember. 1(2): 1.
- Sen S, Raghunathan A. 2018. Approximate Computing for Long Short Term Memory (LSTM) Neural Networks. *IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems*. 37(11): 2266-2276.
- Susanti. 2017. *Peramalan Harga Saham Menggunakan Recurrent Neural Network dengan Algoritma Backpropagation Through Time (BPTT)*. Politeknik Elektronika Negeri Surabaya. 13(2): 1-8.
- Tavinayati, Qamariyanti Y. 2009. *Hukum Pasar Modal di Indonesia*. Jakarta: Sinar Grafika.
- The PSE Academy. 2011. *The PSE Composite Index (PSEi)* [Internet]. [diunduh 2019 Mei 04]. Tersedia pada: [http://www.pseacademy.com.ph/LM/investors~details/id-1317988210702/The\\_PSE\\_Composite\\_Index\\_PSEi.html](http://www.pseacademy.com.ph/LM/investors~details/id-1317988210702/The_PSE_Composite_Index_PSEi.html)
- Yanuar. 2018. *Recurrent Neural Network (RNN)* [Internet]. [diunduh 2019 Mei 11]. Tersedia pada: <http://machinelearning.mipa.ugm.ac.id/2018/07/01/recurrent-neural-network-rnn/>